

Rapport de Stage

Sujet numéro 19 : Salinity forecasting based on AI and Machine Learning

Stage au Danang International Institute of
Technology – Vietnam

MAM 4
Année 2025 - 2026

Encadrant Polytech : M. Jean-Baptiste Caillau
Encadrant DNIIT : M. Vo Ngoc Duong



Rédigé par :
Katell Nio

Sommaire

1	Remerciements	2
2	Introduction	2
3	Description du travail proposé	3
3.1	Le contexte hydrodynamique	3
3.2	La problématique industrielle	3
3.3	La mission du stage	4
3.4	Ouverture	4
4	Description du travail réalisé	5
4.1	Organisation, planning et évolution des objectifs	5
4.2	Le jeu de données	5
4.2.1	Le filtrage des capteurs défectueux	5
4.2.2	La fusion des données et l'alignement du temps	6
4.2.3	Le problème des périodes incomplètes	6
4.3	L'architecture prédictive et le protocole expérimental	6
4.3.1	Le choix de l'année de test	6
4.3.2	Les trois algorithmes choisis	7
4.3.3	Stratégie de prévision	7
4.4	Évaluation et sélection des variables	8
4.4.1	Évaluation et choix des métriques	8
4.4.2	L'Ablation Study (La sélection des variables)	8
4.5	Résultats et analyse des performances	9
4.5.1	Protocole d'évaluation	9
4.5.2	Performances globales	9
4.5.3	Visualisation des prédictions	10
4.5.4	Analyse opérationnelle	10
4.5.5	Recommandation à l'issue du stage	11
5	Conclusion	12
	Bibliographie	13
6	Annexes	14
6.1	Annexe A : Extrait du script Python (Ingénierie des séquences 3D)	14
6.2	Annexe B : Tableau complet de l'Ablation Study	15
6.3	Annexe C : Courbes d'apprentissage du Deep Learning	16

1 Remerciements

Je tiens tout d’abord à remercier l’Université Côte d’Azur et le réseau Polytech pour la mise en place de ce partenariat avec le DNIIT, qui m’a offert l’opportunité de réaliser ce stage à l’international et de vivre une expérience aussi enrichissante.

Mes remerciements s’adressent à mon tuteur de stage au Vietnam, Vo Ngoc Duong, pour m’avoir accueillie au sein de ce projet, ainsi qu’à ma co-tutrice, Ngoc Canh Doan, pour sa réactivité et sa disponibilité lorsque je la sollicitais pour des questions pratiques. Je remercie également M. Jean-Baptiste Caillau, mon tuteur pédagogique à Polytech Nice Sophia, d’avoir accepté d’évaluer ce travail.

Je souhaite exprimer ma sincère gratitude aux étudiants vietnamiens avec qui j’ai collaboré, Huy Anh et Tuong Vy. Leurs conseils avisés, leur aide précieuse pour l’acquisition des données et leur accueil chaleureux ont grandement facilité mon intégration dans le projet ainsi que dans la ville de Da Nang.

Enfin, je remercie tout particulièrement mon binôme, Tahitoa Senis, pour son implication à mes côtés. Notre collaboration équilibrée et nos échanges réguliers ont été essentiels à la progression et à la réussite de notre projet.

2 Introduction

L’accès à l’eau potable est l’un des défis majeurs de notre siècle, notamment dans les régions vulnérables aux changements climatiques. La ville de Da Nang, au centre du Vietnam, fait face à une menace grandissante : l’intrusion saline dans l’estuaire du fleuve Vu Gia – Thu Bon. Durant la saison sèche, la baisse du débit fluvial, couplée à l’élévation du niveau de la mer, permet à l’eau de mer de remonter dans les terres, menaçant directement la station de pompage de Cau Do, source principale d’eau potable de la métropole. Conformément à la norme nationale vietnamienne QCVN 08-MT :2015/BTNMT, le seuil limite de chlorure pour les eaux de surface est fixé à 250 mg/L ; au-delà, la station doit interrompre son pompage, privant potentiellement plus d’un million d’habitants d’eau potable [1].

Mon stage de quatrième année du cycle ingénieur à Polytech Nice Sophia (département Mathématiques Appliquées et Modélisation) s’inscrit directement au cœur de cet enjeu environnemental et sanitaire. L’objectif principal de ce projet est de développer un outil d’aide à la décision basé sur l’Intelligence Artificielle, capable de prédire les pics de salinité 24 heures à l’avance. Cette anticipation est déterminante pour permettre aux opérateurs de l’usine d’ajuster leur stratégie de pompage et de préserver la qualité de l’eau distribuée, un défi accentué par les opérations des barrages en amont [2].

Si l’intrusion saline est un phénomène naturel, elle est amplifiée par le changement climatique et par la modification du régime des débits fluviaux due à la construction et à l’exploitation de grands barrages hydroélectriques en amont [2, 3]. Ces ouvrages, bien qu’essentiels pour la production d’énergie, altèrent la capacité du fleuve à repousser mécaniquement le biseau salé vers l’océan lors des périodes de sécheresse [3].

Ce stage s’est déroulé au Vietnam, au sein du DNIIT (Danang International Institute of Technology), un institut de recherche en partenariat avec l’Université Côte d’Azur. J’ai eu l’opportunité d’évoluer dans un environnement international stimulant, au sein d’une université réunissant des chercheurs et des étudiants vietnamiens.

La réalisation de ce projet s’est faite en binôme avec Tahitoa Senis. Afin d’être efficaces, nous avons choisi de travailler en parallèle sur le traitement des données et la création des algorithmes. Nous avons ensuite régulièrement mis en commun nos avancées et comparé nos résultats pour sélectionner les meilleures approches et construire un modèle de prévision fiable.

Ce rapport présentera les différentes étapes de notre travail. La première partie décrira le contexte physique de la zone d’étude et la dynamique du fleuve. La seconde partie détaillera notre méthodologie, débutant par la préparation d’un jeu de données initialement incomplet, jusqu’à la programmation et l’évaluation des différents modèles de prédiction (XGBoost, LSTM et CNN 1D). Enfin, nous terminerons par une conclusion sur l’utilité concrète de cet outil pour l’usine, ainsi que sur le bilan personnel de cette expérience.

3 Description du travail proposé

Pour comprendre le travail qui nous a été confié, il est indispensable de se pencher sur le phénomène physique à l'œuvre et sur ses conséquences industrielles. Cette section vise à expliciter le problème posé.

3.1 Le contexte hydrodynamique

La dynamique de l'estuaire du fleuve Vu Gia – Thu Bon repose sur l'interaction continue entre l'influence maritime et le débit fluvial. D'un côté, les marées de la Mer de Chine Méridionale (appelée Mer de l'Est au Vietnam) exercent une pression constante vers l'intérieur des terres. L'eau de mer, dont la densité est supérieure à celle de l'eau douce, a tendance à s'infiltrer en profondeur le long du lit du fleuve, formant ce que l'on nomme un « biseau salé ».




FIGURE 1 – Schéma montrant le principe de la formation d'un biseau salé dans un estuaire. *Source : University of Rhode Island, Discovery of Sound in the Sea (DOSITS).*

De l'autre côté, l'eau douce provenant des bassins versants montagneux et des barrages en amont s'oppose à cette intrusion. Son débit (exprimé en m^3/s) crée une barrière hydraulique qui repousse l'océan vers le large.

La position de ce point d'équilibre est dictée par le régime des saisons. Durant la mousson, les crues massives du fleuve chassent totalement le sel vers l'embouchure. En revanche, durant la saison sèche (février à août), avec un pic d'intrusion saline observé entre mars et mai, la situation s'inverse. Les précipitations deviennent quasi nulles, l'évaporation augmente et le débit du fleuve s'affaiblit drastiquement. La pression de l'eau douce n'est alors plus suffisante pour retenir la marée, permettant au biseau salé de remonter silencieusement sur plusieurs kilomètres à l'intérieur des terres [2, 3].

3.2 La problématique industrielle

C'est précisément dans cette zone vulnérable qu'est installée l'usine de traitement des eaux de Cau Do, qui alimente la grande majorité de la ville de Da Nang. La problématique est critique : les pompes et les systèmes de purification de l'usine ne sont pas conçus pour traiter l'eau de mer. Dès que la concentration en chlorure dépasse le seuil légal de 250 mg/L [1], le pompage doit être interrompu sous peine de contaminer le réseau de distribution d'eau potable.

Jusqu'à présent, l'optimisation des pompages repose sur une surveillance réactive des capteurs en temps réel. Disposer d'une prévision fiable de l'intrusion saline permettrait aux opérateurs de gagner un temps précieux. Ce délai d'anticipation leur donnerait la possibilité d'organiser le basculement vers des stations de pompage de secours situées plus en amont, hors d'atteinte du sel (comme la station d'An Trach), et d'assurer ainsi une transition fluide dans l'approvisionnement en eau de la ville.



FIGURE 2 – Localisation de la station de traitement d’eau potable de Cau Do (Nhà Máy Nước Cầu Đỏ) sur le fleuve Vu Gia, à environ 15 km de l’embouchure. *Source : Google Maps.*

3.3 La mission du stage

C’est ici qu’intervient le travail proposé pour ce stage.

Le défi mathématique et informatique posé était le suivant : **concevoir un modèle prédictif de séries temporelles capable d’anticiper la salinité à la station de Cau Do avec une avance de 24 heures.**

Ce délai d’un jour a été ciblé car c’est le temps estimé nécessaire aux équipes de l’usine pour réagir et sécuriser l’approvisionnement sans agir dans l’urgence. Pour y parvenir, notre mission s’est articulée autour du nettoyage, de l’alignement et de la fusion de bases de données hétérogènes (capteurs d’usine, météorologie, débits de barrages), suivis de l’entraînement d’algorithmes d’apprentissage automatique.

3.4 Ouverture

Ce projet d’anticipation de la salinité s’inscrit dans un enjeu bien plus vaste : celui de l’adaptation de nos villes face au dérèglement climatique. Au Vietnam, j’ai pu constater que les phénomènes comme El Niño provoquent des sécheresses de plus en plus extrêmes, qui risquent bientôt de dépasser tout ce que la région a connu jusqu’ici [4].

C’est en réfléchissant à ce contexte, lors de mes recherches bibliographiques, que je me suis intéressée à une limite fondamentale de notre approche. Nos modèles reposent sur des algorithmes dits « statistiques » : ils apprennent des schémas à partir du passé, mais n’ont aucune connaissance des lois physiques qui régissent réellement le déplacement du sel. Je me suis posé la question : que se passera-t-il le jour où une vague de sel d’une intensité inédite se produira ? Dans la mesure où l’usine ne s’intéresse qu’au franchissement d’un seuil, et non à la valeur exacte de la salinité, une erreur de magnitude n’est en soi pas problématique. Le risque est ailleurs : les modèles que nous avons construits n’extrapolent pas au sens strict, mais interpolent dans la plage de valeurs déjà observée pendant l’entraînement. Face à une combinaison de facteurs totalement inédite (un débit d’étiage encore jamais mesuré, par exemple), rien ne garantit que le modèle reconnaîtrait correctement la tendance à la hausse et déclencherait l’alerte à temps, ce qui pourrait, cette fois, avoir de réelles conséquences opérationnelles.

En creusant cette question, j’ai découvert une piste de recherche intéressante pour y répondre : les *Physics-Informed Neural Networks* (PINNs) [5], qui intègrent directement une équation physique (ici, l’équation d’advection-dispersion régissant le transport du sel) comme contrainte dans l’apprentissage, en plus des données observées. L’idée est de forcer le réseau à respecter les lois de conservation même dans les zones où les données manquent, ce qui pourrait en théorie améliorer sa capacité à généraliser à des scénarios extrêmes non observés.

Cette piste reste cependant difficile à mettre en œuvre pour notre cas précis : une véritable équation d’advection-dispersion nécessite des données spatiales le long du fleuve (bathymétrie, sections transversales, plusieurs points de mesure), ainsi qu’un coefficient de dispersion généralement calibré empiriquement, des données que nous n’avons pas à disposition. Coder une telle architecture dépassait donc largement le cadre et le temps imparti pour notre stage, mais explorer ce concept et comprendre ses conditions réelles de faisabilité a été une réflexion scientifique enrichissante.

4 Description du travail réalisé

Le travail réalisé durant ce stage s'est organisé en quatre grandes étapes. Tout d'abord, les premières semaines ont été consacrées à l'étude bibliographique et à la compréhension du contexte environnemental de Da Nang, notamment le fonctionnement de son estuaire. La deuxième phase, qui a demandé le plus de temps et sur laquelle nous sommes revenus régulièrement, a consisté à préparer et nettoyer les différentes données. Ensuite, la troisième étape s'est portée sur la compréhension et la programmation de plusieurs modèles de Machine Learning (XGBoost, CNN 1D, LSTM). Enfin, la dernière partie du projet a été dédiée à l'évaluation de ces modèles en conditions réelles, avec pour objectif d'optimiser leurs prédictions.

4.1 Organisation, planning et évolution des objectifs

Ce projet a été mené avec beaucoup d'autonomie. Notre tuteur nous laissait une grande liberté et nous faisions le point avec lui environ toutes les deux semaines. Avec mon binôme, afin d'être efficaces, nous avons choisi de travailler en parallèle sur le traitement des données et la création des algorithmes. Nous mettions ensuite nos résultats en commun très régulièrement. Cela nous a permis de comparer nos idées, de garder ce qui fonctionnait le mieux, et de fusionner nos meilleurs scripts pour obtenir un code final robuste. Nous avons aussi pu compter sur l'aide de deux étudiants vietnamiens avec qui nous avons régulièrement échangé. Leurs explications sur le contexte local nous ont beaucoup aidés à mieux comprendre notre sujet.

Le planning initial prévoyait une progression linéaire : nettoyage des données, test de modèles standards, puis optimisation. Dans les faits, le déroulement réel du stage a été très différent, principalement parce que nous ne disposions pas de toutes les données dès le début. Nous avons commencé avec seulement la salinité et les niveaux d'eau locaux (marée, fleuve), avant de recevoir, plusieurs semaines plus tard, les débits des barrages en amont, puis, encore plus tard, les données permettant de calculer le gradient hydraulique. Ces données provenaient d'organismes extérieurs à l'usine et leur transmission dépendait de démarches effectuées par notre tuteur, ce qui a introduit des délais d'attente de plusieurs semaines, parfois de plusieurs mois, largement hors de notre contrôle. Cette incertitude sur le calendrier d'arrivée des données a été une des principales difficultés de ce stage : il a fallu apprendre à avancer avec les données disponibles à un instant donné, sans pouvoir garantir qu'une variable jugée utile serait un jour accessible, tout en construisant un pipeline de traitement suffisamment modulaire pour pouvoir intégrer rapidement chaque nouvelle source dès sa réception, sans devoir tout reprendre à zéro.

4.2 Le jeu de données

Comme évoqué précédemment, le plus grand défi de ce stage n'a pas été l'écriture des algorithmes d'Intelligence Artificielle, mais plutôt la préparation des données. Comme nous recevions les fichiers au fur et à mesure et qu'ils provenaient de sources très différentes, nous avons dû faire preuve d'adaptabilité.

4.2.1 Le filtrage des capteurs défectueux

Les données de l'usine, relevées toutes les 15 minutes, contenaient beaucoup d'erreurs dues aux pannes des capteurs immergés. Au lieu de simplement supprimer toutes les valeurs à zéro, nous avons créé des filtres basés sur la logique physique. Nous avons d'abord retiré les valeurs impossibles (comme un niveau d'eau de mer en dehors de la plage $[-5\text{ m}, +5\text{ m}]$). Ensuite, nous avons repéré les « lignes plates » (une valeur qui ne bouge pas pendant 2 heures, signe d'un capteur bloqué ou envasé). Pour les micro-coupures, nous avons reconstruit la donnée par interpolation linéaire. En revanche, nous avons complètement supprimé les pannes trop longues pour ne pas fausser l'apprentissage de nos modèles (comme l'illustre la Figure 3, où l'on observe des valeurs physiquement impossibles).




FIGURE 3 – Visualisation des données brutes du capteur de niveau d’eau. La présence de valeurs physiquement impossibles (pics extrêmes) illustre la nécessité d’un filtrage en amont.

4.2.2 La fusion des données et l’alignement du temps

Nous avons fusionné les données de l’usine avec d’autres sources : les débits des barrages en amont, la météo (via l’API Open-Meteo [6]) et la pente du fleuve (calculée entre les stations de Cau Lau et Hoi An). La difficulté technique était que ces fichiers n’avaient pas tous la même fréquence (certains étaient par heure, d’autres par jour). Nous avons donc dû tout lisser et interpoler pour que chaque variable corresponde exactement au pas strict de 15 minutes de notre base principale.

4.2.3 Le problème des périodes incomplètes

En rassemblant tous ces fichiers, nous sommes tombés sur un dernier obstacle : les dates ne correspondaient pas. Les données des barrages s’arrêtaient fin 2022, alors que certains capteurs d’eau n’avaient commencé à fonctionner qu’en juillet 2019. Plutôt que d’inventer des données manquantes sur plusieurs années, ce qui aurait rendu le modèle aveugle à la réalité physique, nous avons fait un choix : nous avons réduit notre zone d’étude à la seule période où tous les capteurs fonctionnaient en même temps (juillet 2019 à décembre 2022). Nous avons préféré avoir moins de données, mais un historique 100% fiable.

4.3 L’architecture prédictive et le protocole expérimental

Une fois que nous avons un jeu de données propre et exploitable, nous avons pu passer à la création de nos algorithmes.

4.3.1 Le choix de l’année de test

Nous avons entraîné nos algorithmes chronologiquement sur la période juillet 2019 – décembre 2020. Pour vérifier s’ils fonctionnaient bien, nous voulions d’abord les tester sur la dernière année disponible (2022). Mais cette année-là était trop « calme », sans grosse montée de sel. Cela ne nous permettait pas de voir si le modèle pouvait réagir en cas d’urgence. Nous avons donc pris la décision de les tester sur l’année 2021, qui a connu une très forte sécheresse (voir Figure 4). C’était l’épreuve parfaite pour voir si nos modèles pouvaient vraiment anticiper une crise.




FIGURE 4 – Comparaison des niveaux de salinité mesurés à l’usine de Cau Do entre l’année de sécheresse extrême (2021) et une année normale (2022). La ligne pointillée noire représente le seuil légal d’alerte (250 mg/L).

4.3.2 Les trois algorithmes choisis

Pour être sûrs d’obtenir les meilleurs résultats et pour comprendre comment l’IA s’adaptait à notre problème, nous avons mis en compétition trois architectures très différentes (suggérées par notre tuteur) :

- **XGBoost** : il s’agit d’un ensemble d’arbres de décision construits successivement, chaque nouvel arbre cherchant à corriger les erreurs commises par les précédents (une technique appelée *gradient boosting*). Ce modèle est extrêmement rapide et robuste sur des données tabulaires, mais il n’a aucune notion du temps. À un instant t , il traite chaque ligne de données indépendamment, sans savoir ce qui s’est passé juste avant. C’est pourquoi, pour lui, nous avons dû calculer nous-mêmes l’historique des salinités (*lag features*) afin de lui donner artificiellement une forme de mémoire [7].
- **CNN 1D** : généralement utilisé pour reconnaître des images, ce réseau de neurones a ici été adapté pour lire des séries temporelles. Il applique des filtres, de petites fenêtres de quelques valeurs consécutives, qui glissent le long de la courbe du temps et apprennent à reconnaître des motifs locaux récurrents (par exemple, la forme caractéristique d’un cycle de marée). Il est particulièrement doué pour repérer ce type de forme répétitive, mais il ne conserve pas d’information sur le long terme : sa mémoire se limite à la largeur de ses filtres [8].
- **LSTM** : contrairement aux deux modèles précédents, ce réseau de neurones récurrent possède une véritable mémoire interne. À chaque pas de temps, une série de portes (d’entrée, d’oubli, de sortie) régule quelles informations sont conservées, oubliées ou transmises au pas suivant, ce qui lui permet de retenir un contexte sur plusieurs heures, voire plusieurs jours. Il était le candidat parfait pour notre projet, car il est capable de comprendre que l’eau relâchée par un barrage lointain mettra plusieurs heures à arriver et n’aura un impact sur la salinité que plus tard [9, 10].

4.3.3 Stratégie de prévision

Afin de prédire la salinité à un horizon de 24 heures (soit 96 pas de temps), nous avons privilégié une stratégie de prévision directe, c’est-à-dire un modèle entraîné à prédire directement la valeur à $t + 24h$, plutôt qu’une prévision récursive qui enchaînerait 96 prédictions successives à 15 minutes d’intervalle. Ce choix permet d’éviter l’accumulation d’erreurs au fil des pas de temps, un problème fréquent des prédictions récursives [11].

Pour que le CNN et le LSTM comprennent comment l’eau se déplace dans le temps, nous avons également dû restructurer nos données. Au lieu de leur donner une valeur instant par instant, nous leur avons fourni des blocs complets de 24 heures (des fenêtres glissantes, ou *sliding windows*). Notre code rejette automatiquement les blocs qui chevauchent une panne de capteur, afin que l’IA n’apprenne que sur des séquences continues. La fonction Python conçue pour cette tâche de restructuration temporelle est détaillée en **Annexe 6.1**.

Enfin, pour éviter le surapprentissage, nous avons utilisé un arrêt précoce (*early stopping*), qui interrompt l’entraînement dès que la performance sur les données de validation cesse de s’améliorer. Les courbes d’apprentissage correspondantes sont présentées en **Annexe 6.3**.

4.4 Évaluation et sélection des variables

Pour finaliser notre pipeline d'apprentissage, il nous fallait définir comment choisir les meilleures variables et comment noter nos modèles de manière pertinente pour l'usine.

4.4.1 Évaluation et choix des métriques

Pour juger si nos modèles étaient réellement performants, il nous fallait définir comment les noter. Au fil de notre travail, nous avons compris qu'il fallait utiliser deux visions complémentaires : une évaluation purement mathématique (pour juger l'algorithme) et une évaluation "métier" (pour juger l'utilité pour l'usine).

1. Les métriques mathématiques

Nous avons d'abord utilisé les indicateurs classiques en Machine Learning pour mesurer l'écart entre nos courbes de prédiction et la réalité :

- **La MAE (Erreur Absolue Moyenne)** : C'est la métrique la plus simple et la plus intuitive. Elle nous dit, en moyenne, de combien de milligrammes de sel (mg/L) notre IA se trompe chaque jour.
- **La RMSE (Racine de l'Erreur Quadratique Moyenne)** : C'est une métrique plus "sévère" que la MAE, car elle punit très fortement les grosses erreurs (à cause de son calcul au carré).
- **Le R^2 (Coefficient de détermination)** : Il s'agit d'un score variant théoriquement de $-\infty$ à 1 (un score de 1 indiquant une prédiction parfaite) qui évalue si le modèle a bien compris la dynamique générale du fleuve. Un R^2 élevé prouve que l'algorithme a bien saisi le rythme des marées et l'inertie de l'eau, et qu'il ne se contente pas de tracer une ligne moyenne au hasard.

Le piège des saisons :

En regardant nos résultats, nous sommes tombés sur un paradoxe très intéressant avec le climat vietnamien :

- **Pendant la saison des pluies** : L'eau est totalement douce (proche de 0 mg/L tout le temps). Si le modèle se trompe et prédit 5 mg/L, la MAE est excellente (erreur de seulement 5 mg/L). Pourtant, l'ordinateur va nous donner un R^2 catastrophique (voire négatif). Pourquoi ? Parce qu'il n'y a aucune "vague" à deviner, donc le R^2 mathématique n'arrive pas à calculer de score de "forme".
- **Pendant la saison sèche** : C'est l'inverse ! Le sel fait des pics énormes à 2000 mg/L. Si le modèle prédit 1800 mg/L, l'erreur MAE est énorme (200 mg/L de différence). Ça a l'air d'être un mauvais modèle. Mais en réalité, le R^2 sera très bon (proche de 0.8), car le modèle a parfaitement deviné qu'un pic géant allait arriver au bon moment (à titre d'exemple).

2. La métrique de l'usine

À cause de ce piège des saisons, nous avons réalisé que les mathématiques ne suffisaient pas. Pour le directeur de l'usine de Cau Do, se tromper de 50 mg/L en plein hiver n'a aucune importance. La seule chose qui compte, c'est de savoir si le sel va dépasser le seuil d'alerte de 250 mg/L.

Nous avons donc évalué nos modèles comme des systèmes d'alarme :

- **Les crises ratées (Faux Négatifs / Taux de Rappel)** : C'est le scénario le plus problématique. La salinité dépasse 250 mg/L, mais notre modèle n'avait pas anticipé la crise 24 heures à l'avance. L'usine perd alors le bénéfice de l'anticipation : elle ne détectera le dépassement du seuil qu'au moment où il se produit réellement, via sa surveillance réactive habituelle, et devra réagir dans l'urgence plutôt que d'organiser sereinement le basculement vers une station de secours. Notre but numéro 1 était de réduire ce chiffre à zéro (c'est ce qu'on appelle maximiser le « Taux de Rappel »).
- **Les fausses alarmes (Faux Positifs)** : L'IA sonne l'alarme, l'usine s'arrête par précaution, mais finalement le sel n'arrive pas. Ça fait perdre un peu de temps et d'argent à l'usine, mais ce n'est pas dangereux pour la population.

4.4.2 L'Ablation Study (La sélection des variables)

Au départ, nous avons calculé de nombreuses variables candidates. Pour ne conserver que les informations réellement utiles, nous avons conduit une étude d'ablation systématique : chaque groupe de variables a été ajouté individuellement à une base minimale de cinq capteurs bruts, et son impact sur les

performances des deux modèles a été mesuré. Cette analyse a révélé deux comportements opposés selon l’architecture.

Pour **XGBoost**, deux groupes se distinguent nettement. D’une part, les variables décalées de salinité (*lag features*) apportent un gain net en précision globale (R^2 de 0,551 à 0,652). D’autre part, le gradient hydraulique améliore le taux de détection des crises de manière spectaculaire (Recall de 79,1% à 91,8%), au prix d’un taux de fausses alarmes plus élevé (11,6%). Contrairement à notre hypothèse initiale, la configuration combinant l’ensemble des variables (Full, 29 variables) n’est pas optimale : plusieurs groupes (encodage horaire, saisonnalité, pluie) apportent en réalité du bruit qui dilue le signal ($R^2=0,646$ pour le Full, contre 0,551 pour la Baseline seule). La configuration finale retenue pour XGBoost combine donc uniquement les variables décalées de salinité et le gradient hydraulique complet, ce qui offre le meilleur compromis global observé sur l’ensemble de l’étude ($R^2=0,705$, Recall=91,0%, FP=8,1%).

Pour le **LSTM**, le constat est inversé : la grande majorité des groupes de variables dégradent ses performances, parfois légèrement (données de marée : R^2 autour de 0,63-0,65), parfois catastrophiquement (gradient hydraulique : $R^2=-2,50$; ensemble complet Full : $R^2=0,268$, Recall chutant à 30%). Ce résultat confirme que l’architecture à mémoire du LSTM extrait généralement elle-même les dépendances temporelles depuis les séquences brutes, rendant la plupart des variables précalculées redondantes ou perturbantes. Une exception se dégage cependant : l’ajout du seul encodage saisonnier trigonométrique (*month_sin/cos*) améliore sensiblement la reconstruction globale du signal par rapport à la Baseline pure ($R^2=0,745$ contre 0,651), tout en réduisant nettement le taux de fausses alarmes (FP=6,1% contre 13,7%), au prix toutefois d’un recall légèrement inférieur (83,3% contre 90,2%). Nous avons retenu cette configuration comme modèle final pour le LSTM, en privilégiant la robustesse du signal global et la réduction des fausses alarmes, ce compromis restant préférable pour un usage opérationnel continu où un taux de fausses alertes trop élevé finit par ternir la confiance des opérateurs dans le système.

Les résultats de cette étude sont documentés en Annexe 6.2.

4.5 Résultats et analyse des performances

4.5.1 Protocole d’évaluation

Les trois modèles ont été évalués sur la période d’avril à décembre 2021, retenue comme *stress test* en raison de la sécheresse exceptionnelle qui l’a caractérisée : 34,4% du temps au-dessus du seuil critique de 250 mg/L, avec des pics atteignant plusieurs milliers de mg/L. Pour le XGBoost et le LSTM, la configuration de variables retenue est celle ayant obtenu le meilleur compromis lors de l’étude d’ablation systématique décrite en Section 4.4.2. Faute de temps, cette étude d’ablation n’a pas été reconduite pour le CNN 1D, qui a donc été évalué uniquement en configuration brute (les cinq capteurs physiques). Ce choix a été renforcé par le constat que le CNN 1D obtenait, dès les premiers essais, des performances globalement inférieures à celles du LSTM ; nous avons donc préféré concentrer notre effort d’optimisation sur un seul des deux réseaux de neurones plutôt que de le répartir entre les deux.

4.5.2 Performances globales

Modèle	Configuration retenue	R^2	MAE (mg/L)	Recall 250	FP
XGBoost	Optimisé (lags de salinité + gradient hydraulique)	0,705	128,1	91,0%	8,1%
LSTM	+ Saisonnalité (<i>month_sin/cos</i>)	0,745	131,1	83,3%	6,1%
CNN 1D	Baseline (5 capteurs bruts)	0,598	163,3	82,3%	6,6%

TABLE 1 – Performances comparées des trois modèles sur le stress test 2021 (horizon de prévision : +24 heures).

Le Tableau 1 synthétise les configurations optimales identifiées en Section 4.4.2. Deux constats se dégagent. D’une part, aucun des trois modèles ne domine sur tous les critères à la fois : le LSTM offre la meilleure reconstruction globale du signal ($R^2=0,745$), tandis que XGBoost offre le meilleur taux de détection des crises (Recall=91,0%). D’autre part, le CNN 1D reste en retrait sur l’ensemble des métriques ; associé au fait qu’il n’a pas bénéficié de la même étude d’ablation que les deux autres modèles (voir Section 4.5.1), nous l’avons conservé comme point de comparaison mais écarté de la sélection du modèle final.

Ce choix illustre une réalité importante pour un usage industriel : le modèle mathématiquement le plus fidèle à la physique du fleuve n'est pas nécessairement le plus adapté à la mission de sécurité de l'usine. C'est cette différence entre performance globale et fiabilité opérationnelle que nous analysons dans la section suivante.

4.5.3 Visualisation des prédictions




FIGURE 5 – Prévisions à +24h du XGBoost Optimisé et du LSTM + Saisonnalité sur l'année de *stress test* 2021. La ligne orange indique le seuil d'alerte de 250 mg/L.

La Figure 5 permet de comparer visuellement le comportement des deux modèles face à la crise d'avril 2021, la plus intense de l'année. On observe que le LSTM (rouge) suit d'assez près la forme de la courbe réelle et parvient à approcher une amplitude proche de 5000 mg/L au pic le plus fort, tandis que XGBoost (vert) reste nettement plus contenu, plafonnant autour de 2500-3000 mg/L. On remarque également que la montée du LSTM semble parfois légèrement décalée par rapport à la montée réelle, comme si le modèle rattrapait la tendance plutôt que de l'anticiper.

Ces deux observations s'expliquent par la nature de chaque architecture. XGBoost, en tant qu'ensemble d'arbres de décision, ne peut produire qu'une valeur observée (ou une moyenne de valeurs observées) durant l'entraînement pour une combinaison de variables donnée : il ne peut donc pas extrapoler au-delà de l'amplitude déjà rencontrée pour un contexte similaire, ce qui explique son plafonnement lors des pics les plus extrêmes. Le LSTM, à l'inverse, dispose en entrée de la salinité récente au sein de sa séquence, ce qui lui permet d'atteindre des amplitudes plus réalistes, mais l'expose aussi à un effet de « suivi de tendance » lors des remontées les plus brutales, où sa prédiction semble accuser un léger retard sur l'évolution réelle.

D'un point de vue opérationnel, ce léger décalage temporel et cette sous-estimation de l'amplitude ne remettent pas en cause l'utilité des modèles : comme le montre la figure, les deux courbes de prévision franchissent le seuil d'alerte de 250 mg/L avant que le pic réel ne survienne. L'enjeu pour l'usine n'est pas de prédire le chiffre exact, mais de déclencher l'alerte suffisamment à l'avance, ce que les deux modèles parviennent à faire sur l'essentiel de l'année 2021.

4.5.4 Analyse opérationnelle

Dans le contexte de l'usine de Cau Do, toutes les erreurs ne se valent pas. Pour évaluer nos modèles comme de véritables systèmes d'alarme, nous les avons confrontés à la réalité sous la forme d'une matrice de confusion, dont chaque case représente un scénario opérationnel distinct :

- **Vrai Négatif (en haut à gauche)** : le modèle prédit « Normal » et la salinité réelle était effectivement sous le seuil. C'est le fonctionnement courant, sans incident.
- **Faux Positif (en haut à droite)** : le modèle déclenche une alerte alors que la salinité reste sous le seuil. C'est une fausse alarme : l'usine bascule inutilement vers la station de secours, ce qui coûte du temps et de l'énergie.

- **Faux Négatif (en bas à gauche)** : le modèle prédit « Normal » alors que la salinité dépasse en réalité le seuil. C'est l'alerte manquée, le scénario le plus dangereux.
- **Vrai Positif (en bas à droite)** : le modèle déclenche une alerte et une crise se produit effectivement. C'est le fonctionnement recherché du système : la crise est détectée à temps.




FIGURE 6 – Matrices de confusion des deux modèles au seuil de 250 mg/L.

Sur la période de test (avril-décembre 2021), XGBoost ne manque que 513 crises sur 5685 réellement survenues, soit un taux de détection de 91,0%, au prix de 1316 fausses alarmes sur 16240 périodes normales (8,1%). Le LSTM manque davantage de crises (770 sur 4606, soit un recall de 83,3%), mais déclenche moins de fausses alarmes (830 sur 13542, soit 6,1%). XGBoost détecte donc mieux les crises réelles, tandis que le LSTM est un peu plus économe en fausses alertes, un compromis classique entre sensibilité et spécificité, à choisir selon la tolérance de l'usine au risque.

4.5.5 Recommandation à l'issue du stage

Sur la base des données et des modèles développés durant ce stage, XGBoost apparaît comme l'outil le plus adapté à une mise en alerte opérationnelle. Grâce au travail de *Data Engineering* qui lui a fourni une mémoire artificielle, il détecte 9 crises sur 10 avec 24 heures d'avance, un taux supérieur à celui du LSTM (83,3%). Les crises manquées correspondent principalement à des montées de sel particulièrement brutales et soudaines, face auxquelles tout modèle statistique montre ses limites.

Cette recommandation reste toutefois à confirmer dans la suite du projet, qui se poursuit au-delà de ce stage au sein du DNIIT. L'équipe vietnamienne doit notamment recevoir de nouvelles sources de données dans les mois à venir, ce qui permettra de réévaluer ces résultats sur un jeu de données élargi, potentiellement avec de nouvelles variables. Cette évolution pourrait redistribuer les cartes entre les deux architectures : les réseaux de neurones comme le LSTM tirent, en général, davantage profit de l'augmentation du volume de données que les modèles à base d'arbres comme XGBoost, qui atteignent plus rapidement un plafond de performance. Il conviendra donc de réévaluer ce compromis lorsque le jeu de données se sera étoffé.

5 Conclusion

Ce stage de fin de quatrième année au sein du DNIIT s’est révélé être une expérience particulièrement formatrice, tant sur le plan technique qu’humain.

D’un point de vue scientifique, l’objectif principal a été atteint : nous avons réussi à concevoir trois modèles capables d’anticiper les crises salines avec 24 heures d’avance. Le LSTM s’est révélé le plus précis pour reconstituer la dynamique globale du fleuve ($R^2 = 0,745$), tandis que XGBoost, enrichi par l’historique de salinité et le gradient hydraulique, a atteint le meilleur taux de détection opérationnel (Recall = 91,0%). Ce travail a surtout mis en lumière une réalité fondamentale de la Data Science appliquée à l’environnement : la performance d’une Intelligence Artificielle ne dépend pas de la quantité de variables fournies, mais de leur pertinence physique et de leur adéquation avec l’architecture utilisée, l’historique de salinité et le gradient hydraulique ont été la clé permettant à XGBoost de dépasser son absence de mémoire temporelle, alors que ces mêmes variables ont au contraire dégradé les performances du LSTM, dont la mémoire interne suffisait déjà à capter une grande partie de cette information.

Sur le plan personnel et professionnel, travailler au Vietnam dans un contexte interculturel a été extrêmement enrichissant. Évoluer dans un environnement nouveau, avec des jeux de données complexes, parfois incomplets et reçus progressivement au fil du stage, a exigé de ma part une grande capacité d’adaptation. J’ai dû faire preuve d’une forte autonomie pour orienter mes recherches, justifier mes choix d’ingénierie (comme les méthodes d’interpolation et de troncature) et solliciter les bonnes personnes pour pallier les manques de données.

Techniquement, j’ai considérablement consolidé mes compétences en *Data Engineering* avec la librairie Pandas, apprenant à manipuler des séries temporelles asynchrones et à coder des filtres intelligents. J’ai également approfondi ma maîtrise de l’apprentissage automatique (XGBoost) et découvert la puissance des réseaux de neurones récurrents (TensorFlow/Keras) pour capturer l’inertie des systèmes physiques. La collaboration en binôme avec Tahitoa a aussi renforcé ma capacité à travailler en équipe.

Ce travail constitue avant tout une étape dans un projet qui se poursuit au-delà de ce stage. L’équipe du DNIIT continuera à recevoir de nouvelles données dans les mois à venir, ce qui permettra de réévaluer et d’affiner les modèles présentés ici sur un jeu de données élargi. À plus court terme, l’extension à des horizons de prévision multiples (+6h, +12h, +24h) permettrait également d’affiner l’outil opérationnel. À plus long terme, l’exploration des *Physics-Informed Neural Networks* (PINNs) reste une piste intéressante pour dépasser les limites d’extrapolation des modèles purement statistiques face à des scénarios climatiques inédits.

Références

- [1] Ministry of Natural Resources and Environment, “Qcvn 08-mt :2015/btnmt - national technical regulation on surface water quality,” tech. rep., Vietnam Environment Administration, Hanoi, Vietnam, 2015. Consultable sur : <https://www.greencert.com.vn/van-ban-phap-ly/qcvn-08mt2015btnmt-quy-chuan-ky-thuat-quoc-gia-ve-chat-luong-nuoc-mat-3204.html>.
- [2] D. H. Nguyen *et al.*, “Assessments of climate change and sea level rise impacts on flows and saltwater intrusion in the vu gia - thu bon river basin, vietnam,” *International Conference on Asian and Pacific Coasts*, 2019. Consultable sur : https://link.springer.com/chapter/10.1007/978-981-15-0291-0_185.
- [3] H. C. V. Hung Le and T. N. To, “An efficient reservoir operation to reduce saltwater intrusion in the vu gia - thu bon river basin,” *Journal of Hunan University (Natural Sciences)*, vol. 48, no. 10, pp. 193–199, 2021. Consultable sur : <https://jonuns.com/index.php/journal/article/download/764/760>.
- [4] D. N. Phan, T. C. Nguyen, *et al.*, “Vietnam’s water resources : Current status, challenges, and security perspective,” *Sustainability*, vol. 15, no. 8, p. 6441, 2023. Consultable sur : <https://www.mdpi.com/2071-1050/15/8/6441>.
- [5] M. Raissi, P. Perdikaris, and G. E. Karniadakis, “Physics-informed neural networks : A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations,” *Journal of Computational Physics*, vol. 378, pp. 686–707, 2019. Consultable sur : <https://www.sciencedirect.com/article/pii/S0045782519306814>.
- [6] P. Zippenfenig, “Open-meteo.com weather api,” 2023. Consultable sur : <https://open-meteo.com/>.
- [7] T. Chen and C. Guestrin, “Xgboost : A scalable tree boosting system,” in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 785–794, 2016. Consultable sur : <https://dl.acm.org/doi/10.1145/2939672.2939785>.
- [8] S. Kiranyaz, O. Avci, O. Abdeljaber, T. Ince, M. Gabbouj, and D. J. Inman, “1d convolutional neural networks and applications : A survey,” *Mechanical Systems and Signal Processing*, vol. 151, p. 107398, 2021. Consultable sur : <https://www.sciencedirect.com/science/article/pii/S0888327020307846>.
- [9] S. Hochreiter and J. Schmidhuber, “Long short-term memory,” *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997. Consultable sur : <https://direct.mit.edu/neco/article/9/8/1735/6109>.
- [10] F. Kratzert, D. Klotz, C. Brenner, K. Schulz, and M. Herrnegger, “Rainfall–runoff modelling using long short-term memory (lstm) networks,” *Hydrology and Earth System Sciences*, vol. 22, no. 11, pp. 6005–6022, 2018. Consultable sur : <https://hess.copernicus.org/articles/22/6005/2018/>.
- [11] S. B. Taieb, G. Bontempi, A. F. Atiya, and A. Sorjamaa, “A review and comparison of strategies for multi-step ahead time series forecasting,” *Expert Systems with Applications*, vol. 39, no. 8, pp. 7067–7083, 2012. Consultable sur : <https://www.sciencedirect.com/science/article/abs/pii/S0957417412000528>.

6 Annexes

6.1 Annexe A : Extrait du script Python (Ingénierie des séquences 3D)

Ce bloc de code illustre la méthode rigoureuse de fenêtrage glissant (*Sliding Windows*) que nous avons programmée. Elle permet de s'assurer que les modèles de Deep Learning n'apprennent que sur des séquences chronologiques continues, en rejetant automatiquement tout segment comportant des pannes de capteurs ou des sauts temporels.

```
1 def create_3d_sequences(X_s, Y_s, time_index, lookback, horizon):
2     """
3     Creates 3D sliding windows for Deep Learning models (LSTM/CNN),
4     strictly avoiding missing data gaps.
5     """
6     X_seq, Y_seq, dates = [], [], []
7     features = np.hstack((X_s, Y_s)) # Include past salinity in the feature set
8
9     for i in range(len(features) - lookback - horizon):
10         t_win = time_index[i + lookback - 1] - time_index[i]
11         t_tgt = time_index[i + lookback + horizon - 1] - time_index[i + lookback - 1]
12
13         # Verify strict time continuity (no gaps in the 24h history or 24h jump)
14         if (t_win == pd.Timedelta(minutes=15 * (lookback - 1))) and \
15             (t_tgt == pd.Timedelta(minutes=15 * horizon)):
16             X_seq.append(features[i: i + lookback])
17             Y_seq.append(Y_s[i + lookback + horizon - 1])
18             dates.append(time_index[i + lookback + horizon - 1])
19
20     return np.array(X_seq), np.array(Y_seq), pd.DatetimeIndex(dates)
```

6.2 Annexe B : Tableau complet de l’Ablation Study

Cette annexe détaille les résultats de l’étude d’ablation, démontrant l’impact de l’ajout itératif de chaque groupe de variables sur nos modèles de prédiction.

Groupe de variables	N	XGBoost			LSTM		
		R ²	Recall	FP	R ²	Recall	FP
1. Baseline (5 capteurs bruts)	5	0,551	79,1%	4,2%	0,651	90,2%	13,7%
2. + hour_sin/cos	7	0,538	76,8%	3,3%	0,665	90,4%	14,0%
3. + month_sin	6	0,541	75,5%	3,4%	0,705	87,5%	7,3%
4. + month_cos	6	0,513	68,4%	1,8%	0,708	89,8%	9,9%
5. + month_sin/cos	7	0,509	69,8%	2,3%	0,745	83,3%	6,1%
6. + Q_lags (12h-48h)	11	0,531	85,9%	5,4%	0,673	88,0%	14,1%
7. + salinity_lags (1h-24h)	11	0,652	77,1%	2,9%	0,689	90,7%	12,3%
8. + sal_lags courts (1h-4h)	8	0,633	76,1%	2,4%	0,672	89,3%	12,5%
9. + sal_lags longs (8h-24h)	8	0,551	80,0%	3,8%	0,683	91,6%	14,9%
10. + tide_mean_6h	6	0,508	79,0%	3,8%	0,648	87,1%	11,0%
11. + tide_max_6h	6	0,523	78,4%	4,2%	0,632	81,2%	9,2%
12. + tide_mean+max_6h	7	0,538	73,7%	3,2%	0,654	83,9%	8,5%
13. + rain_24h	6	0,549	82,0%	4,9%	0,684	88,6%	13,2%
14. + rain_48h	6	0,520	85,5%	5,8%	0,689	89,5%	11,7%
15. + rain_24h+48h	7	0,518	86,2%	6,4%	0,690	90,1%	11,0%
16. + Gradient_deltas (6h-48h)	8	0,605	91,8%	11,6%	-2,502	89,9%	50,1%
17. FULL (toutes features)	29	0,646	88,6%	6,1%	0,268	30,0%	18,9%

TABLE 2 – Résultats de l’Ablation Study pour l’horizon +24h. Le groupe « Baseline » correspond aux 5 variables brutes : salinité, niveau de marée, niveau du fleuve et débits des deux barrages. Les colonnes FP indiquent le taux de Faux Positifs, tandis que le Recall mesure le taux de détection des crises (seuil de 250 mg/L). La configuration LSTM + Saisonnalité correspond exactement au groupe 5 ci-dessus. La configuration XGBoost Optimisée, en revanche, combine les lags de salinité et le gradient hydraulique complet sans reprendre les autres variables du groupe FULL (voir Section 4.4.2 pour le détail).

6.3 Annexe C : Courbes d'apprentissage du Deep Learning

Le graphique ci-dessous illustre le suivi de l'entraînement de l'architecture LSTM sur les ensembles de formation (Training Loss) et de validation (Validation Loss). Il illustre le phénomène de surapprentissage : la loss d'entraînement (bleu) continue de décroître tandis que la loss de validation (orange) remonte, signe que le modèle mémorise les données d'entraînement au lieu de généraliser. Le mécanisme d'Early Stopping restaure automatiquement les poids correspondant au minimum de la courbe de validation.




FIGURE 7 – Courbes d'apprentissage (Loss) du modèle LSTM mettant en évidence la nécessité de l'arrêt précoce.